# Apprentissage Supervisé Classification

## Arbres de décision

# Content


1. Définition et exemple
2. Algorithme
3. Construction d'arbre de décision
4. Conclusion

# Arbres de Décision

## Motivation

Produire des classifications compréhensibles par l'utilisateur (versus les autres méthodes)

# Arbres de Décision

## Motivation

Produire des classifications compréhensibles par l'utilisateur (versus les autres méthodes)

## Définition

Ensemble de règles de classification basant leur décision sur des tests associés aux attributs, organisés de manière arborescente.

# Arbres de Décision

## Motivation

Produire des classifications compréhensibles par l'utilisateur (versus les autres méthodes)

## Définition

Ensemble de règles de classification basant leur décision sur des tests associés aux attributs, organisés de manière arborescente.

## Objectif

L'objectif est de créer un modèle qui prédit les valeurs de la variable cible, en se basant sur un ensemble de séquences de règles de décision déduites à partir des données d'apprentissage.

# Arbres de Décision

## Motivation

Produire des classifications compréhensibles par l'utilisateur (versus les autres méthodes)

## Définition

Ensemble de règles de classification basant leur décision sur des tests associés aux attributs, organisés de manière arborescente.

## Objectif

L'objectif est de créer un modèle qui prédit les valeurs de la variable cible, en se basant sur un ensemble de séquences de règles de décision déduites à partir des données d'apprentissage.

## Remarque

Un arbre de décision (decision tree) est une structure très utilisée en Machine learning. Son fonctionnement repose sur des heuristiques construites selon des techniques d'apprentissage supervisées.

# Arbre de Décision

- Les arbres de décision ont une structure hiérarchique.
- Les arbres de décision sont composés de noeuds et de feuilles reliés par des branches.
- Dans leur représentation graphique, la racine est placée en haut et les feuilles en bas.
- Les noeuds internes sont appelés des noeuds de décision.
- Les noeuds internes peuvent contenir une ou plusieurs règles (aussi appelées tests ou conditions).

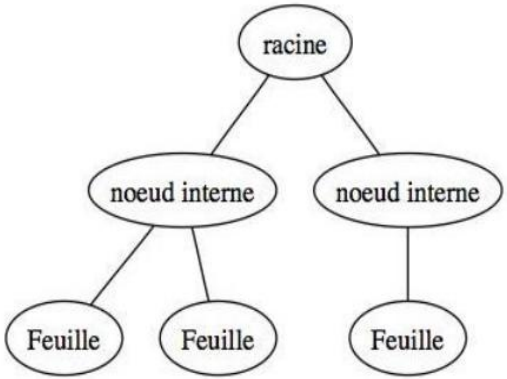

# Généralités sur les arbres de décision

- Les valeurs que peut prendre une variable dans un arbre de décision sont appelées instances ou attributs.
- Les noeuds terminaux contiennent la classe aussi appelée classe à prédire ou variable cible.
- Après sa construction, un arbre de décision peut être traduit sous la forme d'un ensemble de règles de décision.
- Lorsque la classe à prédire est une variable qualitative, nous avons un arbre de classification.
- Si la classe à prédire est une variable quantitative, nous avons un arbre de régression.

# Exemple

**Arbre de décision**

Décider si une institution bancaire peut accorder ou non un prêt à un demandeur de prêt.

# Exemple

**Arbre de décision**

Décider si une institution bancaire peut accorder ou non un prêt à un demandeur de prêt.

- La décision de la variable cible **Prêt** se base sur les variables moyenne du salaire **(MoySal)**, âge **(âge)** et possession d'autres comptes **(Autres comptes)**.
- Les attributs des feuilles de l'arbre: **Prêt**, sont des valeurs booléennes qui correspondent à une classification dans l'ensemble **{Oui, Non}**.

# Exemple

**Arbre de décision**

Décider si une institution bancaire peut accorder ou non un prêt à un demandeur de prêt.

- La décision de la variable cible **Prêt** se base sur les variables moyenne du salaire **(MoySal)**, âge **(âge)** et possession d'autres comptes **(Autres comptes)**.
- Les attributs des feuilles de l'arbre: **Prêt**, sont des valeurs booléennes qui correspondent à une classification dans l'ensemble **{Oui, Non}**.

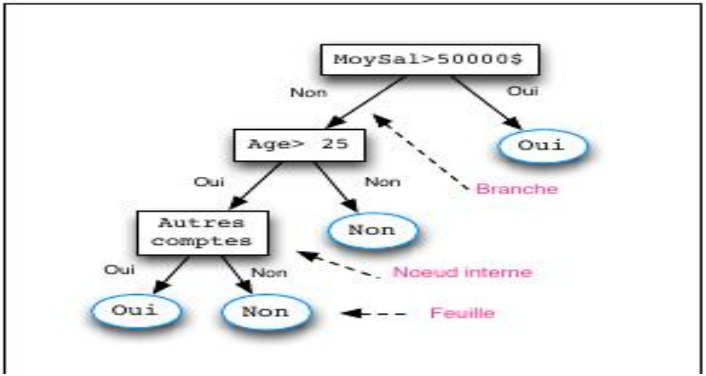

# Exemple

Cet arbre de décision engendre les règles de décisions suivantes:

- Si **MoySal** $> 50000\$$ alors **Prêt = Oui**.
- Si **MoySal** $< 50000\$$ et **Âge** $< 25$ alors **Prêt = Non**.
- Si **MoySal** $< 50000\$$ et **Âge** $> 25$ et **AutresComptes = Oui** alors **Prêt = Oui**.
- Si **MoySal** $< 50000\$$ et **Âge** $> 25$ et **AutresComptes = Non** alors **Prêt = Non**.

# Exemple

Cet arbre de décision engendre les règles de décisions suivantes:

- Si **MoySal** $> 50000\$$ alors **Prêt = Oui**.
- Si **MoySal** $< 50000\$$ et **Âge** $< 25$ alors **Prêt = Non**.
- Si **MoySal** $< 50000\$$ et **Âge** $> 25$ et **AutresComptes = Oui** alors **Prêt = Oui**.
- Si **MoySal** $< 50000\$$ et **Âge** $> 25$ et **AutresComptes = Non** alors **Prêt = Non**.

L'institution est en mesure de décider facilement si elle accorde ou non un prêt à un demandeur.

# Algorithmes de construction d'arbres de décision.

Début Algorithme

Input :

- E : ensemble d'échantillons
- L : ensemble d'attributs.

Output:

- un arbre de décision

Faire :

1. Si tous les exemples sont de la même classe
   - Alors créer et retourner une feuille étiquetée par cette classe.
2. Sinon
   1. Répéter
      1. Trouver le meilleur attribut dans l'ensemble L : A
      2. Répartir les exemples de E en n sous-ensembles, selon la valeur de cet attribut.
      3. Allouer un noeud étiqueté par A
      4. Refaire le même processus pour toutes les valeurs de A et faire de ces noeuds
      5. les fils du noeud étiqueté par A
   2. Jusqu'à indice d'arrêt.

Fin Algorithme

# Algorithme pour construire les arbres de décision

Il existe plusieurs algorithmes automatiques pour construire les arbres de décision:

- **ID3 (Iterative Dichotomiser 3)**: dévelopé en 1986 par Ross Quinlan.
  - Il peut être appliqué seulement sur les caractéristiques nominales.
  - Il est utilisé pour le classement.
- **C4.5:** une extension de ID3 par Ross Quinlan.
  - Il peut être appliqué sur tous les types de caractéristiques.
  - Il est utilisé pour le classement.
- **C5.0:** une extension commerciale de C4.5, toujours par Ross Quinlan.
- **CART (Classification and Regression Trees)**

# Algorithme pour construire les arbres de décision

## Algorithme CART

- Parmi les plus performants et plus répandus (Scikit-learn)
- Accepte tout type de variables
- Utilise le Critère de séparation : Indice de Gini
- L'algorithme récursif CART (Classification And Regression Trees) permet la construction d'un arbre de décision par la maximisation de l'indice de Gini.
- Cet algorithme génère des arbres de décision binaires.
- Construit un arbre de décision avec CART se fait en deux étapes:
  1. Un arbre maximal (indice de Gini)
  2. Élagage: on construit une suite de sous arbres optimaux élagués de l'arbre maximal (ccp)

# Indice de Gini

- L'indice de Gini est une mesure d'impureté des ensembles de données, utilisée pour construire des arbres de décision.
- Il permet d'évaluer la qualité d'un nœud et sa capacité à séparer les différentes classes.
- Pour un ensemble de données $T$ contenant $m$ classes, l'indice de Gini est défini par :

$$\mathrm{GINI}(T) = 1 - \sum_{j=1}^{m} \left( \frac{|T_j|}{|T|} \right)^2$$

  où $|T_j|$ est le nombre d'exemples de la classe $j$ dans $T$.
- Lorsqu'on sépare l'ensemble $T$ en sous-ensembles $T_1, T_2, \ldots, T_k$ selon un attribut $X$, le gain d'information associé est :
  Si $T$ est partitionné en sous-ensembles $T_1, T_2, \ldots, T_k$ selon un attribut $X$, le gain de Gini associé à cette division est :

$$\text{Gain de Gini}(X, T) = \mathrm{GINI}(T) - \sum_{i=1}^{k} \frac{|T_i|}{|T|} \mathrm{GINI}(T_i)$$

- Le gain de Gini mesure la réduction d'impureté obtenue après la partition et sert à choisir la meilleure division lors de la construction de l'arbre.

# Construction d'arbre de décision: Exemple banque

| client | M | A | R | E | I |
|---|---|---|---|---|---|
| 01 | moyen | moyen | village | oui | oui |
| 02 | élevé | moyen | bourg | non | non |
| 03 | faible | âgé | bourg | non | non |
| 04 | faible | moyen | bourg | oui | oui |
| 05 | moyen | jeune | ville | oui | oui |
| 06 | élevé | âgé | ville | oui | non |
| 07 | moyen | âgé | ville | oui | non |
| 08 | faible | moyen | village | non | non |

# Construction d'arbre de décision: Exemple banque

| client | M | A | R | E | I |
|---|---|---|---|---|---|
| 01 | moyen | moyen | village | oui | oui |
| 02 | élevé | moyen | bourg | non | non |
| 03 | faible | âgé | bourg | non | non |
| 04 | faible | moyen | bourg | oui | oui |
| 05 | moyen | jeune | ville | oui | oui |
| 06 | élevé | âgé | ville | oui | non |
| 07 | moyen | âgé | ville | oui | non |
| 08 | faible | moyen | village | non | non |

- M: moyenne des montants sur le compte client.
- A: tranche d'âge du client.
- R: localité de résidence du client.
- E: valeur oui si le client a un niveau d'études supérieures.
- I: classe oui correspond à un client qui utilise internet pour consulter ses comptes.

# Construction d'arbre de décision: Exemple banque

| client | M | A | R | E | I |
|---|---|---|---|---|---|
| 01 | moyen | moyen | village | oui | oui |
| 02 | élevé | moyen | bourg | non | non |
| 03 | faible | âgé | bourg | non | non |
| 04 | faible | moyen | bourg | oui | oui |
| 05 | moyen | jeune | ville | oui | oui |
| 06 | élevé | âgé | ville | oui | non |
| 07 | moyen | âgé | ville | oui | non |
| 08 | faible | moyen | village | non | non |

- M: moyenne des montants sur le compte client.
- A: tranche d'âge du client.
- R: localité de résidence du client.
- E: valeur oui si le client a un niveau d'études supérieures.
- I: classe oui correspond à un client qui utilise internet pour consulter ses comptes.

Indice de Gini avant séparation ($IG(as)$):
8 clients:

- $I$ = oui: 3 clients
- $I$ = non: 5 clients

$$IG(as) = 1 - \left(\left(\frac{3}{8}\right)^2 + \left(\frac{5}{8}\right)^2\right) = 0.46875$$

- $\frac{3}{8}$: Fréquence de $I$ = oui
- $\frac{5}{8}$: Fréquence de $I$ = non

# Calcul de l'indice de Gini pour la variable $M$

L'indice de Gini mesure l'impureté d'un attribut et aide à choisir le meilleur split dans un arbre de décision.

**1. M = Faible ($N_1$=3)** : Oui=1, Non=2
$IG_1 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - (\frac{1}{9} + \frac{4}{9}) = \frac{4}{9}$

**2. M = Moyen ($N_2$=3)** : Oui=2, Non=1
$IG_2 = 1 - \left((\frac{2}{3})^2 + (\frac{1}{3})^2\right) = 1 - (\frac{4}{9} + \frac{1}{9}) = \frac{4}{9}$

**3. M = Élevé ($N_3$=2)** : Oui=0, Non=2
$IG_3 = 1 - \left((\frac{0}{2})^2 + (\frac{2}{2})^2\right) = 1 - (0 + 1) = 0$

# Calcul de l'indice de Gini pour la variable $M$

L'indice de Gini mesure l'impureté d'un attribut et aide à choisir le meilleur split dans un arbre de décision.

**1. M = Faible ($N_1$=3)** : Oui=1, Non=2
$IG_1 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - (\frac{1}{9} + \frac{4}{9}) = \frac{4}{9}$

**2. M = Moyen ($N_2$=3)** : Oui=2, Non=1
$IG_2 = 1 - \left((\frac{2}{3})^2 + (\frac{1}{3})^2\right) = 1 - (\frac{4}{9} + \frac{1}{9}) = \frac{4}{9}$

**3. M = Élevé ($N_3$=2)** : Oui=0, Non=2
$IG_3 = 1 - \left((\frac{0}{2})^2 + (\frac{2}{2})^2\right) = 1 - (0 + 1) = 0$

**Gain de Gini pour M** $= IG(\text{a.s}) - \sum_{k=1}^{3} \frac{N_k}{N} IG_k$

$$= 0.46875 - \left(\frac{3}{8} \cdot \frac{4}{9} + \frac{3}{8} \cdot \frac{4}{9} + \frac{2}{8} \cdot 0\right)$$
$$= 0.1354167$$

# Calcul de l'indice de Gini pour la variable $A$

**1. A = Jeune ($N_1$=1)** : Oui=1, Non=0
$IG_1 = 1 - \left((\frac{1}{1})^2 + (\frac{0}{1})^2\right) = 1 - (1 + 0) = 0$

**2. A = Moyen ($N_2$=4)** : Oui=2, Non=2
$IG_2 = 1 - \left((\frac{2}{4})^2 + (\frac{2}{4})^2\right) = 1 - \left(\frac{1}{4} + \frac{1}{4}\right) = 0.5$

**3. A = Âgé ($N_3$=3)** : Oui=0, Non=3
$IG_3 = 1 - \left((\frac{0}{3})^2 + (\frac{3}{3})^2\right) = 1 - (0 + 1) = 0$

# Calcul de l'indice de Gini pour la variable $A$

**1. A = Jeune ($N_1$=1)** : Oui=1, Non=0

$IG_1 = 1 - \left((\frac{1}{1})^2 + (\frac{0}{1})^2\right) = 1 - (1+0) = 0$

**2. A = Moyen ($N_2$=4)** : Oui=2, Non=2

$IG_2 = 1 - \left((\frac{2}{4})^2 + (\frac{2}{4})^2\right) = 1 - \left(\frac{1}{4} + \frac{1}{4}\right) = 0.5$

**3. A = Âgé ($N_3$=3)** : Oui=0, Non=3

$IG_3 = 1 - \left((\frac{0}{3})^2 + (\frac{3}{3})^2\right) = 1 - (0+1) = 0$

**Gain de Gini pour A**

$$\begin{aligned} &= IG(\text{a.s}) - \sum_{k=1}^{3} \frac{N_k}{N} IG_k \\ &= 0.46875 - \left(\frac{1}{8} \cdot 0 + \frac{4}{8} \cdot 0.5 + \frac{3}{8} \cdot 0\right) \\ &= 0.21875 \end{aligned}$$

# Calcul de l'indice de Gini pour la variable $R$

**1. R = Village ($N_1$=2)** : Oui=1, Non=1
$IG_1 = 1 - \left((\frac{1}{2})^2 + (\frac{1}{2})^2\right) = 1 - \left(\frac{1}{4} + \frac{1}{4}\right) = 0.5$

**2. R = Bourg ($N_2$=3)** : Oui=1, Non=2
$IG_2 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - \left(\frac{1}{9} + \frac{4}{9}\right) = 0.444444$

**3. R = Ville ($N_3$=3)** : Oui=1, Non=2
$IG_3 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - \left(\frac{1}{9} + \frac{4}{9}\right) = 0.444444$

# Calcul de l'indice de Gini pour la variable $R$

**1. R = Village ($N_1$=2)** : Oui=1, Non=1

$IG_1 = 1 - \left((\frac{1}{2})^2 + (\frac{1}{2})^2\right) = 1 - \left(\frac{1}{4} + \frac{1}{4}\right) = 0.5$

**2. R = Bourg ($N_2$=3)** : Oui=1, Non=2

$IG_2 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - \left(\frac{1}{9} + \frac{4}{9}\right) = 0.444444$

**3. R = Ville ($N_3$=3)** : Oui=1, Non=2

$IG_3 = 1 - \left((\frac{1}{3})^2 + (\frac{2}{3})^2\right) = 1 - \left(\frac{1}{9} + \frac{4}{9}\right) = 0.444444$

**Gain de Gini pour R**

$$\begin{aligned} &= IG(\text{a.s}) - \sum_{k=1}^{3} \frac{N_k}{N} IG_k \\ &= 0.46875 - \left(\frac{2}{8} \cdot 0.5 + \frac{3}{8} \cdot 0.444444 + \frac{3}{8} \cdot 0.444444\right) \\ &= 0.0104167 \end{aligned}$$

# Calcul de l'indice de Gini pour la variable $E$

**1. E = Oui ($N_1$=5)** : Oui=3, Non=2

$IG_1 = 1 - \left( (\frac{3}{5})^2 + (\frac{2}{5})^2 \right) = 1 - \left( \frac{9}{25} + \frac{4}{25} \right) = 0.48$

**2. E = Non ($N_2$=3)** : Oui=0, Non=3

$IG_2 = 1 - \left( (\frac{0}{3})^2 + (\frac{3}{3})^2 \right) = 1 - (0 + 1) = 0$

# Calcul de l'indice de Gini pour la variable $E$

**1. E = Oui ($N_1$=5)** : Oui=3, Non=2

$IG_1 = 1 - \left((\frac{3}{5})^2 + (\frac{2}{5})^2\right) = 1 - \left(\frac{9}{25} + \frac{4}{25}\right) = 0.48$

**2. E = Non ($N_2$=3)** : Oui=0, Non=3

$IG_2 = 1 - \left((\frac{0}{3})^2 + (\frac{3}{3})^2\right) = 1 - (0 + 1) = 0$

**Gain de Gini pour E**

$$\begin{aligned} &= IG(\text{a.s}) - \sum_{k=1}^{2} \frac{N_k}{N} IG_k \\ &= 0.46875 - \left(\frac{5}{8} \cdot 0.48 + \frac{3}{8} \cdot 0\right) \\ &= 0.16875 \end{aligned}$$

# Choix de la meilleure variable pour la racine

Nous comparons les gains de Gini obtenus pour chaque variable :

$$G_M = 0.1354, \qquad G_A = 0.21875, \qquad G_R = 0.0104, \qquad G_E = 0.16875$$

# Choix de la meilleure variable pour la racine

Nous comparons les gains de Gini obtenus pour chaque variable :

$$G_M = 0.1354, \qquad G_A = 0.21875, \qquad G_R = 0.0104, \qquad G_E = 0.16875$$

$$\Rightarrow \boxed{\text{La meilleure variable est } A \text{ (gain maximal)}}$$

# Choix de la meilleure variable pour la racine

Nous comparons les gains de Gini obtenus pour chaque variable :

$$G_M = 0.1354, \qquad G_A = 0.21875, \qquad G_R = 0.0104, \qquad G_E = 0.16875$$

$$\Rightarrow \boxed{\text{La meilleure variable est } A \text{ (gain maximal)}}$$

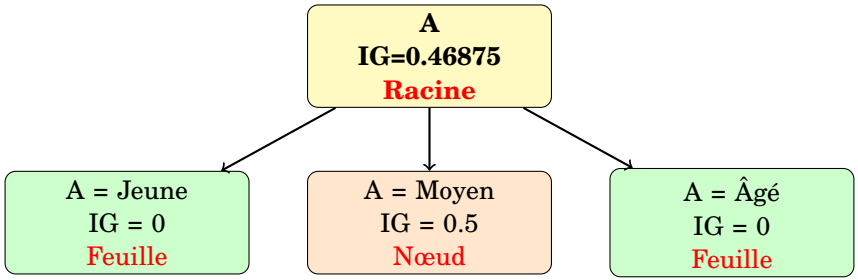

# Sous-ensemble : $A$ = Moyen

Données extraites du dataset pour $A$ = Moyen :

| client | $M$ | $R$ | $E$ | $I$ |
|---|---|---|---|---|
| 01 | $moyen$ | $village$ | $oui$ | $oui$ |
| 02 | $élevé$ | $bourg$ | $non$ | $non$ |
| 04 | $faible$ | $bourg$ | $oui$ | $oui$ |
| 08 | $faible$ | $village$ | $non$ | $non$ |

# Sous-ensemble : $A$ = Moyen

Données extraites du dataset pour $A$ = Moyen :

| client | $M$ | $R$ | $E$ | $I$ |
|---|---|---|---|---|
| 01 | $moyen$ | $village$ | $oui$ | $oui$ |
| 02 | $élevé$ | $bourg$ | $non$ | $non$ |
| 04 | $faible$ | $bourg$ | $oui$ | $oui$ |
| 08 | $faible$ | $village$ | $non$ | $non$ |

Nombre total : $N = 4$
Oui = 2, Non = 2

# Sous-ensemble : $A$ = Moyen

Données extraites du dataset pour $A$ = Moyen :

| client | $M$ | $R$ | $E$ | $I$ |
|---|---|---|---|---|
| 01 | $moyen$ | $village$ | $oui$ | $oui$ |
| 02 | $élevé$ | $bourg$ | $non$ | $non$ |
| 04 | $faible$ | $bourg$ | $oui$ | $oui$ |
| 08 | $faible$ | $village$ | $non$ | $non$ |

Nombre total : $N = 4$
Oui = 2, Non = 2

$$IG_{A=moyen} = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 1 - \frac{1}{4} - \frac{1}{4} = \frac{1}{2} = 0.5$$

# Gains de Gini pour $M$, $R$, $E$ au nœud $A$ = Moyen

$$IG_{A=moyen} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

**1. Split sur M**
$\Rightarrow moyen : IG = 0$ $élevé : IG = 0,\ faible : IG = 0.5$
Somme pondérée = 0.25
$\Rightarrow \boxed{G(M) = 0.25}$

# Gains de Gini pour $M$, $R$, $E$ au nœud $A$ = Moyen

$$IG_{A=moyen} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

**1. Split sur M**
$\Rightarrow$ $moyen : IG = 0$ $élevé : IG = 0,$ $faible : IG = 0.5$
Somme pondérée = 0.25
$\Rightarrow$ $\boxed{G(M) = 0.25}$

**2. Split sur R**
Village : $IG = 0.5$, Bourg : $IG = 0.5$
Somme pondérée = 0.5
$\Rightarrow$ $\boxed{G(R) = 0}$

# Gains de Gini pour $M$, $R$, $E$ au nœud $A$ = Moyen

$$IG_{A=moyen} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

**1. Split sur M**
$\Rightarrow$ $moyen : IG = 0$ $élevé : IG = 0,$ $faible : IG = 0.5$
Somme pondérée = 0.25
$\Rightarrow$ $\boxed{G(M) = 0.25}$

**2. Split sur R**
Village : $IG = 0.5$, Bourg : $IG = 0.5$
Somme pondérée = 0.5
$\Rightarrow$ $\boxed{G(R) = 0}$

**3. Split sur E**
Oui : $IG = 0$, Non : $IG = 0$
Somme pondérée = 0
$\Rightarrow$ $\boxed{G(E) = 0.5}$

# Gains de Gini pour $M$, $R$, $E$ au nœud $A$ = Moyen

$$IG_{A=moyen} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

**1. Split sur M**
$\Rightarrow$ $moyen : IG = 0$ $élevé : IG = 0,$ $faible : IG = 0.5$
Somme pondérée = 0.25
$\Rightarrow$ $\boxed{G(M) = 0.25}$

**2. Split sur R**
Village : $IG = 0.5$, Bourg : $IG = 0.5$
Somme pondérée = 0.5
$\Rightarrow$ $\boxed{G(R) = 0}$

**3. Split sur E**
Oui : $IG = 0$, Non : $IG = 0$
Somme pondérée = 0
$\Rightarrow$ $\boxed{G(E) = 0.5}$

$$G(M) = 0.25$$

$$G(R) = 0$$

$$G(E) = \mathbf{0.5}$$

$\boxed{\text{Meilleur attribut : } E}$

# Sous-arbre pour $A$ = Moyen

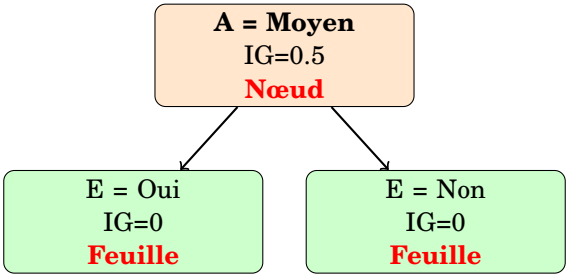

# Sous-arbre pour $A$ = Moyen

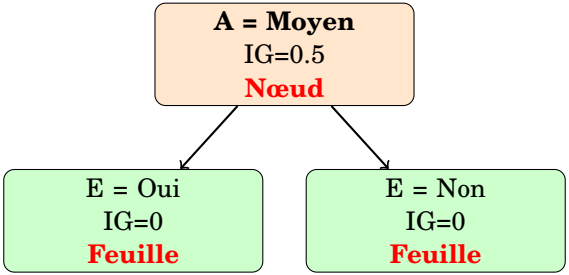


**Toutes les feuilles sont pures, alors on s'arrête**

# Arbre de décision final

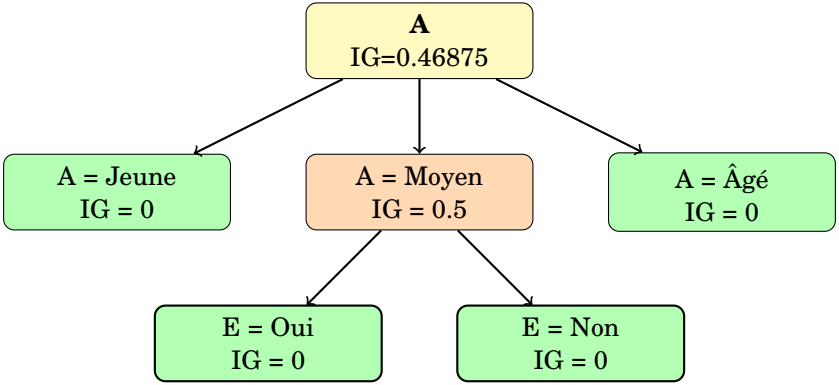

# Entropie

- L'entropie est une mesure d'impureté utilisée dans les arbres de décision (ID3, C4.5).
- Elle indique le degré de mélange des classes dans un ensemble de données.
- Pour un ensemble $T$ contenant $m$ classes, l'entropie est :

$$\text{Entropie}(T) = -\sum_{j=1}^{m} \frac{|T_j|}{|T|} \log_2 \left( \frac{|T_j|}{|T|} \right)$$

- Plus l'entropie est élevée, plus le nœud est impur.
- Lorsqu'on sépare l'ensemble $T$ en sous-ensembles $T_1, T_2, \ldots, T_k$ selon un attribut $X$, le gain d'information associé est :

$$\text{Gain}(X, T) = \text{Entropie}(T) - \sum_{i=1}^{k} \frac{|T_i|}{|T|} \text{Entropie}(T_i)$$

- Le meilleur attribut est celui qui maximise le gain d'information.

# Avantages et Inconvénients

## Avantages

- Simples à comprendre et à interpréter.
- Ils peuvent travailler sur des données avec peu de préparation.
- Ils acceptent les données numériques et nominales.
- Ils donnent de bonne performance même si leurs hypothèses sont un peu violées par le modèle réel à partir duquel les données ont été générées.

# Avantages et Inconvénients

## Avantages

- Simples à comprendre et à interpréter.
- Ils peuvent travailler sur des données avec peu de préparation.
- Ils acceptent les données numériques et nominales.
- Ils donnent de bonne performance même si leurs hypothèses sont un peu violées par le modèle réel à partir duquel les données ont été générées.

## Inconvénients

- Ils peuvent être aussi complexes, ils ne généralisent pas bien (overfitting: surapprentissage).
- Ils peuvent être instable à cause des variations des données.
- Ils peuvent être biaisés à la classe dominante.
- Ce n'ai pas garanti de tomber sur l'arbre de décision optimal.

# MERCI POUR VOTRE ATTENTION